



UNIVERSIDADE FEDERAL DO CEARÁ
CENTRO DE TECNOLOGIA
DEPARTAMENTO DE ENGENHARIA DE TELEINFORMÁTICA

Engenharia de Telecomunicações

Professor: Charles Casimiro Cavalcante
Disciplina: Processos Estocásticos – TI0112

Separação Supervisionada de Fontes Independentes

JÚLIO CÉSAR GAMA FEITOSA FREITAS- 385467
KENNETH BRENNER DOS ANJOS BENÍCIO – 385468
LUCAS DE FREITAS SOUZA – 385471
LUCAS DE SOUZA ABDALAH – 385472

Fortaleza, 7 de julho de 2017

Sumário

INTRODUÇÃO AO PROBLEMA	3
METODOLOGIA EMPREGADA (PROCEDIMENTO).....	4
FUNDAMENTOS DA SOLUÇÃO PROPOSTA.....	5
Parte 1.....	5
Parte 2.....	6
IMPLEMENTAÇÃO (UTILIZANDO OCTAVE).....	8
ANÁLISE DOS RESULTADOS (CONCLUSÃO).....	18
BIBLIOGRAFIA.....	19

Introdução ao Problema

Somos apresentados a um problema, encontrado por uma perícia forense. Nesse problema, dois microfones distintos, utilizados pela perícia, realizam gravações de áudio de participantes de uma reunião, em uma mesma sala. Cada microfone capta a mesma informação, porém com diferentes intensidades de cada sinal de voz, assumindo então que estão distribuídos de forma diferente dentro da sala. Em meio a este cenário caótico, temos a informação da presença de um locutor específico, do qual temos conhecimento de sua contribuição final por um terceiro áudio. Sabendo disso, temos a separação das vozes contidas no áudio como objetivo principal. Consequentemente, devemos estimar o número de locutores, presentes em ambos os microfones, e fazer uma estimativa, de forma que cada voz seja inteligível para o usuário. Podemos perceber, de antemão, que se trata de um caso parecido com o “*Cocktail Party Problem*”, onde temos vários convidados em uma mesma sala.

Antes de tudo, devemos identificar as fontes fornecidas pela perícia. Pelo problema apresentado, temos a informação da existência de dois microfones (*Mic1* e *Mic2*) e de um áudio final (Y) de uma das vozes separadas e sem ruído (limpa). Como temos o conhecimento da existência de um dos sinais de voz isolados, sabe-se que se trata de um problema de separação de áudio assistida, onde nos é fornecida a informação de, pelo menos, uma das componentes da mistura. Durante este processo, definimos dois passos importantes para a separação de vozes dos áudios, a fim de solucionar o problema. Primeiramente, com a informação do áudio Y , devemos retirar o sinal de voz do locutor específico do *Mic1* e do *Mic2*. Com isso, podemos seguir para o segundo passo, onde separamos os sinais de vozes restantes e analisamos suas relações estatísticas.

Visto isso, devemos adotar uma abordagem de solução para cada problema. Na primeira parte, resolvemos o empecilho observando a média do áudio Y e por meio de manipulações estatísticas (descritas posteriormente) que reduzem o problema de um sistema de 2 equações (número de misturas) com 3 incógnitas (número de fontes) para um de apenas 2 incógnitas. Já na segunda parte, adotamos um método de solução de separação supervisionada aplicando conhecimentos adquiridos de Álgebra Aplicada e utilizando conceitos de separação a cegas para obter os áudios originais.

Após encontrar as contribuições originais para a mistura, nossa missão se reduz a analisar os resultados obtidos. Devemos calcular e plotar o gráfico de autocorrelação e a densidade espectral de potência (DEP) dos sinais de áudio, verificar se é possível e, se sim, o que se pode inferir dos sinais do *Mic1* a partir de sua Função de Autocorrelação.

Não somente isso, desejamos, também, identificar as principais características dos sinais das Fontes e gerar variáveis aleatórias que emulam o comportamento estatístico dos sinais. Por fim, chegamos a uma conclusão em relação a “inteligibilidade sonora” dos áudios.

Todos os pontos abordados acima serão expostos ao longo do trabalho.

Metodologia Empregada (Procedimento)

No seguinte projeto, foram utilizadas implementações do Octave , análises algébricas, por meio de matrizes, e noções probabilísticas conhecidos de longa data (Média, variância, Autocorrelação, Funções de distribuição etc) e referenciados ao longo do mesmo. Por fim, nota-se como principal fundamento, motivação e desenvolvimento do trabalho o uso de conhecimentos a cerca de Processos Estocásticos, adquiridos na disciplina.

Fundamentos da Solução Proposta

Parte 1 - Removendo o y de Cada Microfone

I) O ponto inicial é a modelagem do problema. Como sabemos exatamente o sinal y , podemos modelar os vetores $Mic1$ e $Mic2$ como valores aleatórios P_1 e P_2 quaisquer somados a y multiplicado por constantes k_1 e k_2 .

$$Mic1 = P_1 + k_1 * y$$

$$Mic2 = P_2 + k_2 * y$$

II) Desenvolvendo os cálculos de algumas propriedades estatísticas pros sinais podemos observar as constantes k_1 e k_2 . Temos que observar também que P_1 e y são eventos independentes. Sabemos que média μ_y e variância θ_y^2 são definidas como: $\mu_y = \mathbb{E}\{y\}$; $\theta_y^2 = \mathbb{E}\{y^2\} - \mu_y^2$. Sabemos que a média μ_y é bem próxima de zero, então podemos fazer as seguintes afirmações:

$$i) \mu_y \rightarrow 0$$

$$ii) \theta_y^2 \rightarrow \mathbb{E}\{y^2\}$$

Fazendo a correlação entre os vetores de áudios:

$Mic1$ e y :

$$R_y(Mic1, y) = \mathbb{E}\{Mic1 * y\}$$

$$\dots = \mathbb{E}\{(P_1 + k_1 * y) * y\}$$

$$\dots = \mathbb{E}\{y * P_1\} + k_1 \mathbb{E}\{y^2\}$$

$$\dots = \mathbb{E}\{y\} * \mathbb{E}\{P_1\} + k_1 * \mathbb{E}\{y^2\}$$

$$\dots = k_1 * \mathbb{E}\{y^2\}$$

$$k_1 = R_y(Mic1, y) / \theta_y^2$$

$Mic2$ e y :

$$R_y(Mic2, y) = \mathbb{E}\{Mic2 * y\}$$

$$\dots = \mathbb{E}\{(P_2 + k_2 * y) * y\}$$

$$\dots = \mathbb{E}\{y * P_2\} + k_2 \mathbb{E}\{y^2\}$$

$$\dots = \mathbb{E}\{y\} * \mathbb{E}\{P_2\} + k_2 * \mathbb{E}\{y^2\}$$

$$\dots = k_2 * \mathbb{E}\{y^2\}$$

$$k_2 = R_y(Mic2, y) / \theta_y^2$$

III) Sabendo as constantes k_1 e k_2 podemos multiplicar pelo vetor de variáveis y e obter aproximadamente os valores de y contido nos vetores $Mic1$ e $Mic2$.

$$y_1 = k_1 * y$$

$$y_2 = k_2 * y$$

Restando apenas subtrair y_1 e y_2 de $Mic1$ e $Mic2$, respectivamente:

$$M_1 = Mic1 - y_1$$

$$M_2 = Mic2 - y_2$$

Assim finaliza a primeira parte e é visível que ao soar os vetores M_1 e M_2 , o locutor y não será mais notado.

Parte 2 - Estimando as Vozes Restantes

I) Inicialmente uma análise sobre as componentes restantes do microfones é feita e o seguinte modelo é proposto:

$$\begin{aligned}S_1 &= aP_1 + bP_2 \\ S_2 &= cP_1 + dP_2\end{aligned}$$

Sendo S_1 e S_2 são os sinais de áudio após a retirada do locutor y . Já P_1 e P_2 são as diferentes vozes identificadas na modelagem do problema. Por últimos teremos os coeficientes do sistema linear: a , b , c e d .

II) Representando matricialmente o sistema:

$$S = AP$$

A é definida como a matriz de mistura do sistema e assim como o nome indica, a responsável por concatenar os vetores das vozes em uma mistura linear dos microfones. Assim, podemos afirmar que umas das formas de estimar as vozes da modelagem é calculando a matriz de “desmistura” do sistema, que seria o inverso da matriz de mistura:

$$P = A^{-1}S$$

Sendo S a Matriz dos microfones, P a Matriz das vozes propostas na modelagem, A é Matriz dos coeficientes, finalmente A^{-1} que é a Matriz inversa de A .

III) Interpretando estatisticamente a matriz A :

Os coeficientes do sistema inicial fornecem uma pista do que essa matriz pode significar. Cada microfone contém “pedaços” de informações das vozes P_1 e P_2 . Sendo assim, uma forma de se obter a representação mais verossímil possível da reconstrução dessas vozes acontece quando juntamos as informações dessas em cada microfone. Uma forma de quantificar isso é através de uma matriz de correlação. Logo, uma boa alternativa para resolver o problema é interpretar essa matriz A como uma matriz de correlação dos microfones com as vozes.

IV) Analisando mais a fundo como as características dos sinais moldarão a matriz de correlação:

Sabe-se que uma matriz de correlação tem relação com uma matriz de covariância pela seguinte associação. (No caso a matriz qualquer $M_{2 \times 2}$):

$$C_x = R_x - \mu_1 * \mu_2$$

Sabendo que μ_1 e μ_2 representam os valores médios dos vetores aleatórios que compõem M_1 e M_2 (que são os microfones 1 e 2 com o locutor y já removido). Como é possível ver na imagem abaixo, são praticamente nulos. Concluindo assim que a correlação tende à covariância:

$$C_x \rightarrow R_x$$

Fazendo com que a matriz de correlação possua as mesmas propriedades da matriz de covariância, o problema reduz-se a calcular a matriz de covariância dos microfones.

V) Calculando a matriz de Covariância (Correlação) por meio do operador esperança $\mathbb{E}\{\cdot\}$:
As operações são realizadas sabendo médias são nulas e que $S = AP$.

$$\begin{aligned}C_x &= \mathbb{E}\{(S-\mu)(S-\mu)^T\} \\C_x &= \mathbb{E}\{SS^T\} - \mu\mu^T \\C_x &\rightarrow R_x = \mathbb{E}\{SS^T\} \\R_x &= \mathbb{E}\{(AP)(AP)^T\} \\R_x &= \mathbb{E}\{APA^T P^T\}\end{aligned}$$

Além de que as matrizes A e A^T são constantes, já que podem ser interpretadas como a forma que o operador do sistema embaralha as fontes sonoras.

$$R_x = A \mathbb{E}\{PP^T\} A^T$$

Onde $\mathbb{E}\{PP^T\} = \mathbb{E}\{I\} = I$. Isso ocorre porque a matriz das vozes possui duas fontes que são estatisticamente decorrelacionadas, algebricamente isso se reflete na ortogonalidade dos vetores das vozes. Sendo assim, sabe-se que caso os dois vetores sejam ortogonais vale o resultado

$$PP^T = \text{Matriz Identidade.}$$

Por consequência:

$$R_x = A I A^T$$

É fácil visualizar que a matriz identidade é o elemento de multiplicação neutro em espaços matriciais, logo teremos as seguintes consequências.

$$\begin{aligned}AI &= A \\R_x &= AA^T\end{aligned}$$

Lembrando que a matriz A é, por propriedade da matriz de correlação simétrica, então $A=A^T$

$$R_x = A^2$$

Por fim, teremos a seguinte relação, onde A é a matriz de mistura e A^{-} é a matriz de separação.

$$\begin{aligned}A &= R_x^{1/2} \\A^{-} &= R_x^{-1/2}\end{aligned}$$

VI) Reescrevendo a matriz A^{-} elemento a elemento:

$$\begin{pmatrix} \mathbb{E}\{S_1^2\} & \mathbb{E}\{S_1 S_2\} \\ \mathbb{E}\{S_1 S_2\} & \mathbb{E}\{S_2^2\} \end{pmatrix}^{-1/2}$$

Implementação usando OCTAVE

Inicialmente, é necessário carregar as variáveis fornecidas no manual do trabalho. Habilitando o diretório desejado no Gerenciador de Arquivos do Octave e dando duplo clique nos arquivos de extensão “.mat” os mesmos são carregados no *Ambiente de Trabalho*.

Assim sucessivamente, até carregar todos os arquivos.

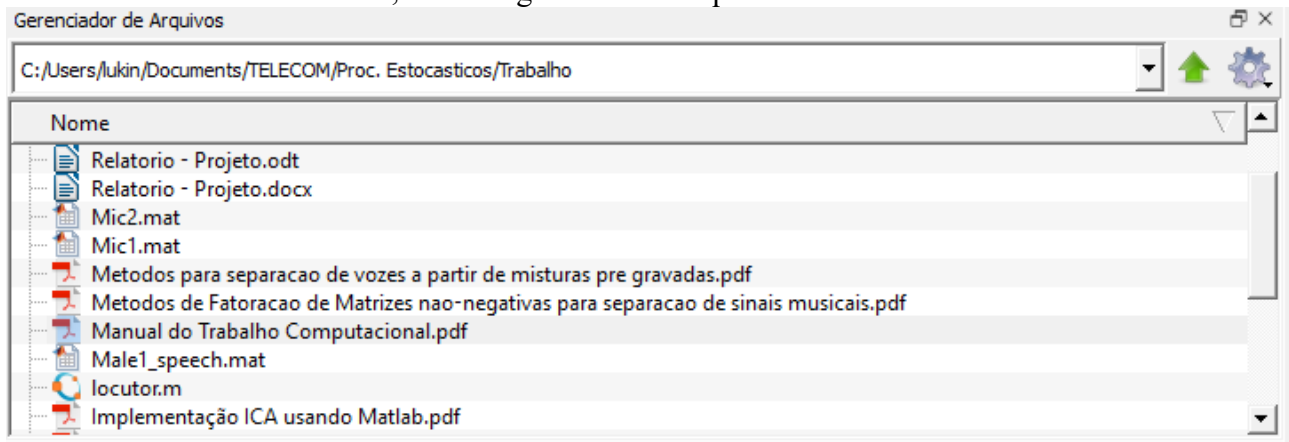


Figura 1: Área de Trabalho do Octave

Nome	Classe	Dimensão	Valor	Atributo
y	double	318769x1	[5.7983e-004; 0.0013123; 8.5449e-0...	
Mic2	double	1x276625	[-0.0014795, 0.012447, 0.0029898, -...	
Mic1	double	1x276625	[0.013140, 0.0027240, 0.0011891, -0...	
Fs	double	1x1	8000	

Figura 2: Variáveis Carregadas

F_s é a taxa de amostragem que é fornecida junto aos sinais de áudio. Y é um sinal de áudio com a voz do narrador, sinal esse que também está presente nos vetores $Mic1$ e $Mic2$ que contém a captação de diversas vozes em um ambiente com ruído.

Como podemos ver, Y é uma matriz linha, logo temos que transpô-la para podermos trabalhar com ela. É visível que o vetor de variáveis y está contido em ambos os áudios captados, porém em menor intensidade, logo há constantes a e b multiplicando o vetor y , sendo $0 < (a, b) < 1$.

```
>> y = y(1:k);
>> clear ans
>> for i = 1:1:k
c(i) = Mic1(i)*y(i);
end
>> corly = mean(c)
corly = 0.0031404
>> a = (corly)/var(y);
>> ya = a*y;
>> Mic1a = Mic1 - ya;
>> sound(Mic1a)

>> for i = 1:1:k
d(i) = Mic2(i)*y(i);
end
>> cory2 = mean(d)
cory2 = 0.0015784
>> b = (cory2)/var(y);
>> yb = b*y;
>> Mic2b = Mic2 - yb;
>> sound(Mic2b)
```

Figura 3: Implementação da retirada do locutor y dos $Mic1$ e 2 .


```
>> Mic1 - ya;          >> Mic2 - yb;
>> sound(ans)          >> sound(ans)

>> mean(ans)           >> mean(ans)
ans = -7.7435e-005 ans = -1.2087e-004
```

Figura 4: Médias de M_1 e M_2 , embasam a segunda parte da separação de vozes

```
>> e11 = corr(Mica1, Mica1)
e11 = 1.0000
>> e12 = corr(Mica1, Micb2)
e12 = 0.89537
>> e21 = corr(Micb2, Mica1)
e21 = 0.89537
>> e22 = corr(Micb2, Micb2)
e22 = 1.00000
```

Figura 5: Cálculo das correlações

```
>> M = [e11 e12; e21 e22]
M =

    1.00000    0.89537
    0.89537    1.00000
```

Figura 6: Criação da Matriz A

```
>> M = M^(-0.5)
M =

    1.9089   -1.1826
   -1.1826    1.9089
```

Figura 7: Cálculo da Matriz $A^{-1/2}$

```
>> x1 = (M(1,1))*Mica1 + (M(1,2))*Micb2;
>> x2 = (M(2,1))*Mica1 + (M(2,2))*Micb2;
```

Figura 8: Estimando os sinais X_1 e X_2 , os sinais das vozes

Nas páginas seguintes teremos o script do códigos e os plots necessários.

```

1  %PROBLEMAS 1 e 2
2  % (PARTE 1) Separacao do Malel_speech
3  % Aqui carregamos os vetores
4  load('Mic1.mat');
5  load('Mic2.mat');
6  load('Malel_speech.mat');
7
8  % Fazendo a transposicao e "corte" do vetor y
9  y = y';
10 y = y(1:length(Mic1));
11
12 %A partir de agora utilizamos os calculos demonstrados anteriormente
13 %Mic1
14 for i = 1:1:length(Mic1)
15     c(i) = y(i)*Mic1(i);
16 end;
17 cory1 = mean(c);
18 k1 = cory1/var(y);
19 M1 = Mic1 - k1*y;
20 %Aqui temos o Mic1 sem a voz do Locutor
21
22 %Mic2
23 for i = 1:1:length(Mic2)
24     d(i) = y(i)*Mic2(i);
25 end;
26 cory2 = mean(d);
27 k2 = cory2/var(y);
28 M2 = Mic2 - k2*y;
29 %Aqui temos o Mic2 sem a voz do Locutor
30
31 % (PARTE 2) Aplicacoes Algebricas
32 %Calculo dos coeficientes de correlacao
33 e11 = corr(M1,M1);
34 e12 = corr(M1,M2);
35 e21 = corr(M2,M1);
36 e22 = corr(M2,M2);
37
38 %Aqui construimos a matriz dos coeficientes de Correlacao
39
40 %entre os microfones (Sem o sinal de Y)
41 M = [e11 e12; e21 e22];
42
43 %Fazemos a opecao da raiz da Matriz M
44 M = M^(-0.5);
45
46 %Agora utilizamos os coeficientes das matrizes obtidas
47 X1 = (M(1,1))*M1 + (M(1,2))*M2;
48 X2 = (M(2,1))*M1 + (M(2,2))*M2;
49
50 %PROBLEMA 3
51 acy = xcorr(y);
52 acM1 = xcorr(X1);
53 acM2 = xcorr(M2);
54
55 %Plot das autocorrelacoes
56 %y
57 plot(acy);
58 title('Autorrelacao de y');
59 xlabel('Amostras');
60 %X1
61 plot(X1);
62 title('Autorrelacao de X1');
63 xlabel('Amostras');
64 %X2
65 plot(X2);
66 title('Autorrelacao de X2');
67 xlabel('Amostras');

```

Funções de Autocorrelação

Como se pode ver, todos os gráficos têm uma forma bem próxima umas das outras. A partir da análise desses gráficos é visível que o nível de correlação desses sinais uns com os outros é baixo, impossibilitando uma interpretação empírica desses sinais no estado em que se encontram. Isso deve principalmente ao alto grau de aleatoriedade presente na fala de uma pessoa (frequência, timbre), dificultando a modelagem de uma voz usando apenas um tipo de função.

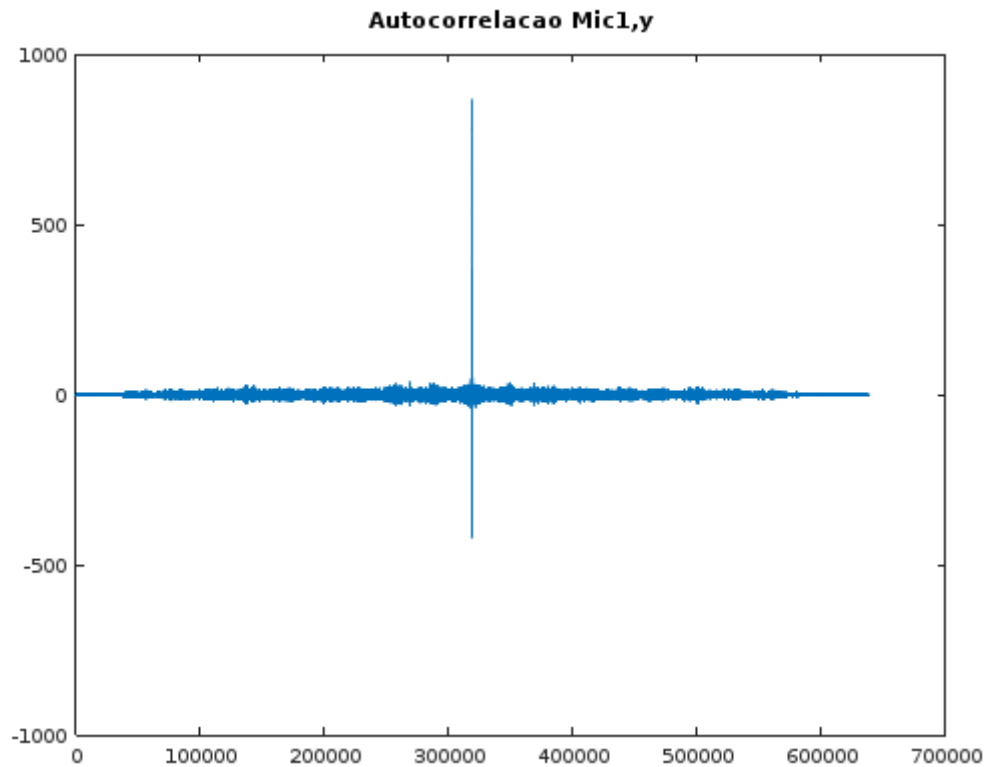


Figura 9: Plot da Autocorrelação de Mic1, Y




Figura 10: Plot da Autocorrelação de Mic2, Y

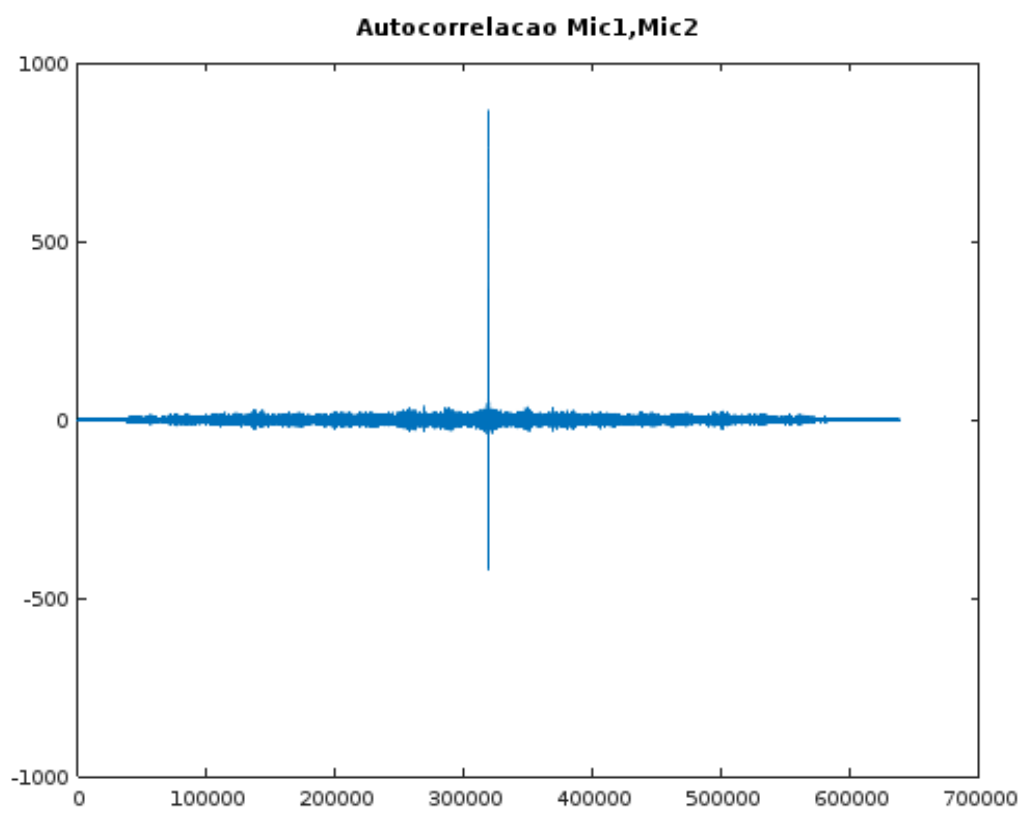


Figura 11: Plot da Autocorrelação de Mic1, Mic2

Densidade Espectral de Potência (DEP)

Aqui vemos o cálculo(plot) da função de densidade espectral de potência(DEP). Ele é realizado através da transformada de Fourier aplicada na função de correlação do processo estocástico. Desse modo, podemos garantir a existência dessa operação tratando o processo estocástico como sendo estacionário, recorrendo ao Teorema de Wiener–Khinchin para garantir a validade dessa suposição. Essa opção é utilizada quando o sinal de áudio não possui uma integral quadrada calculável, o que significaria que o sinal possuiria força média não nula.




Figura 12: Cálculo da DEP do locutor y

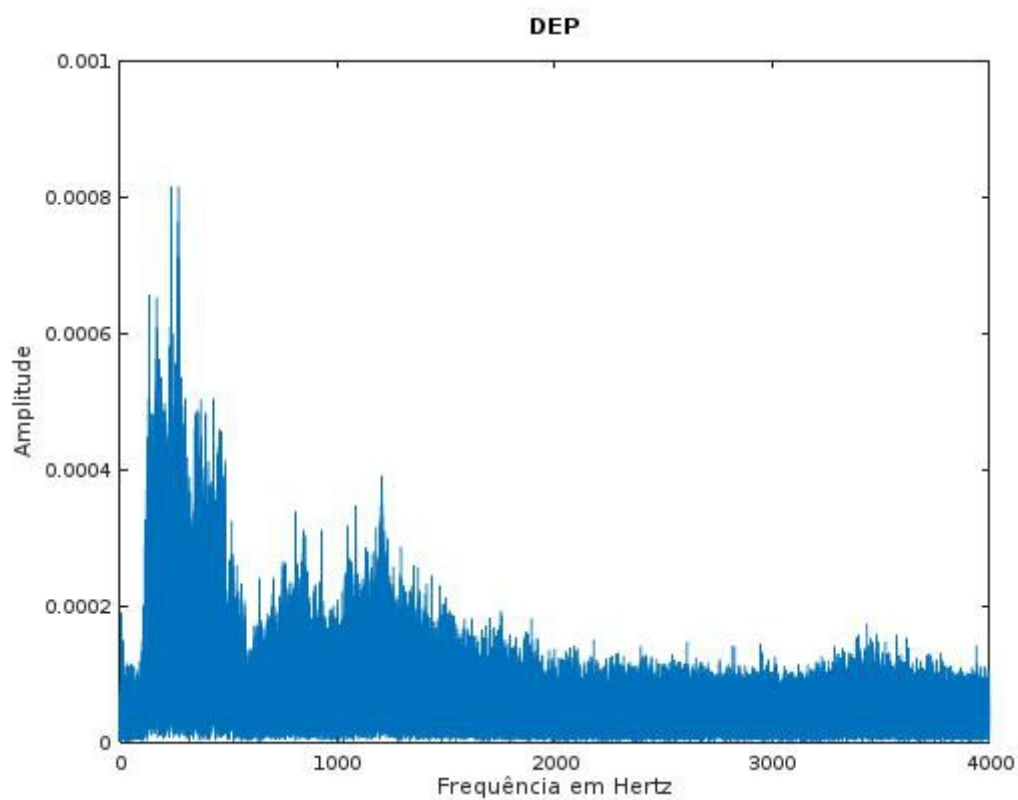


Figura 13: Cálculo da DEP do áudio X1 (voz 1 separada)

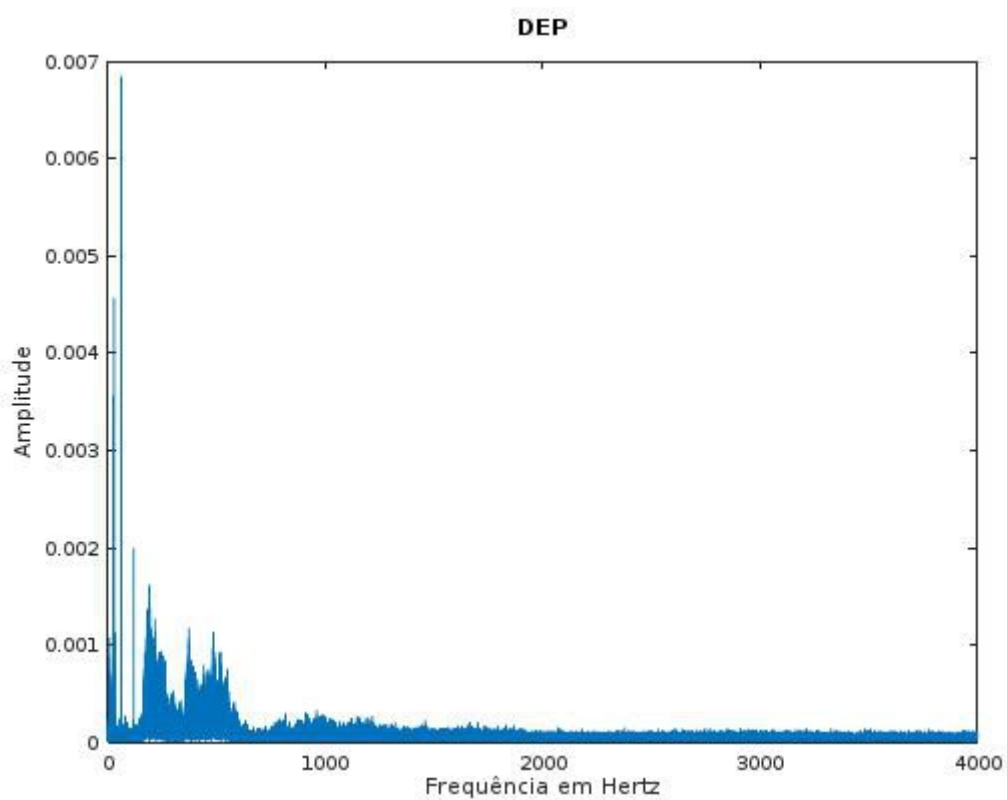


Figura 14: Cálculo da DEP do áudio X2 (voz 2 separada)

Gerador Aleatório

Geramos os histogramas de cada um dos áudios separados, com o objetivo de analisar suas características estatísticas. Pelo que se pode perceber, ambos possuem uma forte semelhança com a distribuição de Cauchy. Sendo assim, geramos a variável aleatória, emulando o resultado obtido por ambos os áudios. Abaixo podemos visualizar os histogramas:




Figura 12: Histograma do áudio X1

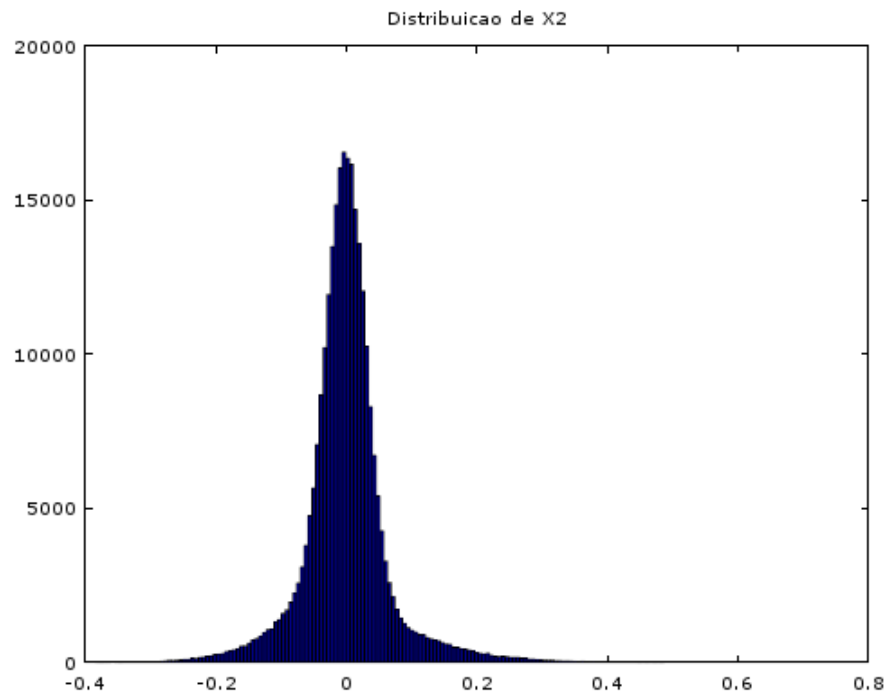


Figura 13: Histograma do áudio X2




Figura 14: Histograma do áudio Y

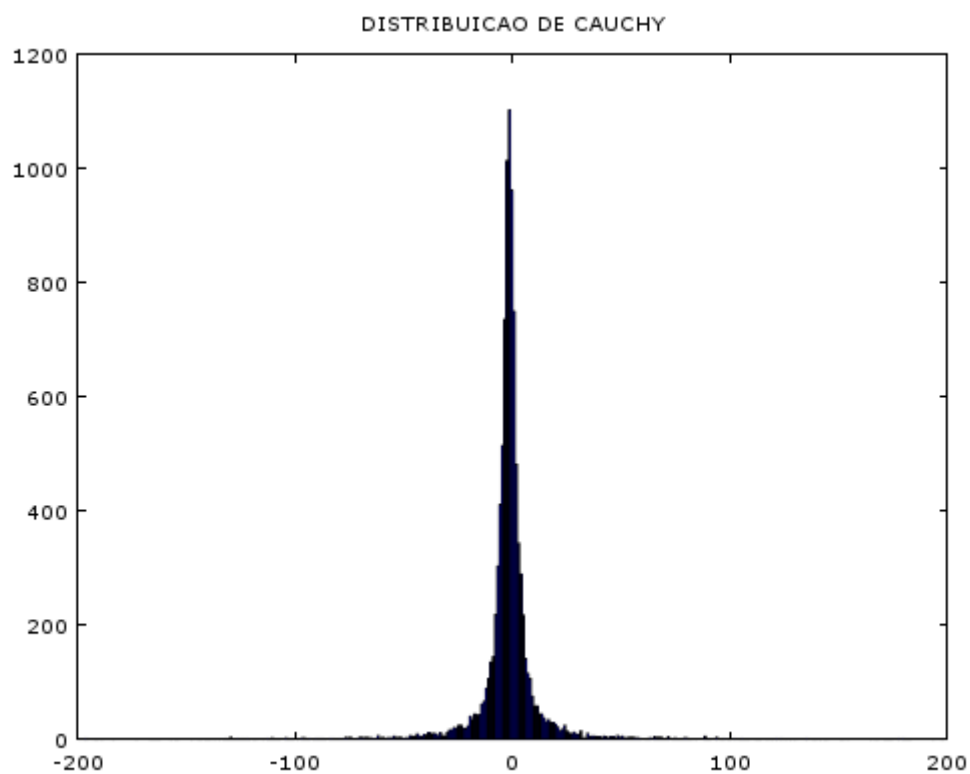


Figura 15: Histograma da distribuição de Cauchy gerada a partir de uma variável aleatória

A seguir podem ser vistos os comandos executados para gerar cada um dos histogramas e para gerar uma variável aleatória com distribuição de Cauchy:

```
1 hist(X1,150); %Histograma de x1 em um intervalo de 150 divisões
2 title('DISTRIBUICAO DE X1')
3
4 hist(X2,150); %Histograma de x2 em um intervalo de 150 divisões
5 title('DISTRIBUICAO DE X2')
6
7 hist(y,150); %Histograma de y em um intervalo de 150 divisões
8 title('DISTRIBUICAO DE Y')
```

Figura 16: Geração dos Histogramas X1, X2 e Y

```
1 function y = unifor_GenRan(N = 1, inf = 0, sup = 1); %Exerce a mesma função de unifor_Gen
2 %Alterando apenas os limites inferior e superior para 0 e 1
3 clc;
4 %Diferente do problema anterior, a exponencial acontece nos intervalos de 0 a 1
5 a = 7;
6 b = 11;
7 m = 2^32;
8 seed = clock;
9 seed = ((10^3)*seed(6));
10 x = zeros(1,N);
11 x(1) = seed;
12
13 for h = 2:N
14     x(h) = mod((a*x(h-1)+b),m);
15 end
16 x = x/(m-1);
17
18 y = (x*(sup-inf))+inf;
19
20 endfunction
21 %Utilizada para alimentar as outras funções de distribuição (Gaussiana, exponencial e Cauchy)
```

Figura 17: Geração de uma variável aleatória

```
1 function Y = unifor_GenCauchy() %Função de geração da distribuição de Cauchy
2 alfa = 3; %Atribui valor 4 ao lambda
3 k = 10000; %10000 amostras
4 z = unifor_GenRan(10000,-10,10); %A variável z recebe valores gerados pela função uniforme 2
5 x = sort(z); %Atribui à variável x o vetor ordenado de z
6
7 for i = 1:k; %Laço que percorre do primeiro vetor ao vetor 10000
8     Y(i) = alfa*tan(x(i)*pi)-(pi/2); %Função inversa da Cauchy
9 %Utilizada para gerar as sequências com a distribuição
10 end
11 figure 1;
12 hist(Y,50000); %Histograma de distribuição cauchy por 50 000 divisões
13 title('DISTRIBUICAO DE CAUCHY')
14 med = 0; %Atribui valor inicial 0 a média
15
```

Figura 18: Função para Plotagem de Histograma de uma Função de Distribuição de Cauchy

Como as fontes de áudio possuem uma distribuição próxima a de Cauchy, podemos afirmar que não existe inteligibilidade sonora, visto que se trata de um gerador aleatório. Sendo assim, nos áudios executados a partir dessa geração seria observado apenas ruído.

Análise dos Resultados

O problema inicialmente se mostra bem complexo e exige uma boa “bagagem” de estudo estatístico e algébrico para modelar e utilizar qualquer proposta de resolução. O desenvolvimento e aplicação do primeiro método se mostrou extremamente eficaz, pois foram utilizadas aproximações bem razoáveis e condizentes com a proposta de estimar os sinais. As vozes mostraram fidelidade ao que supõe-se ter sido gravado individualmente.

Ao aplicar o método estatístico na primeira parte da solução temos uma margem de erro muito baixa e que apesar do ruído observado, é perceptível que o locutor y foi totalmente separado e não influencia mais os vetores de áudio M_1 e M_2 .

Já no segundo método empregado, tivemos uma margem de erro um pouco maior devido a aproximações mais “grosseiras” devido o método utilizado, porém conseguindo estimar de forma bastante satisfatória cada áudio gravado.

A questão do ruído ser tratado ou não foge do escopo do trabalho, já que o ruído contido é branco, logo está em todas as frequências e seria muito difícil, talvez impossível, de reduzi-lo de forma totalmente satisfatória.

Com o uso do Octave foi possível observar características em cada sinal de voz e tomar conclusões descritas durante todo o projeto. E além disso pudemos observar que a distribuição das vozes se assemelha a uma distribuição de probabilidade conhecida e anteriormente estudada.

Bibliografia

- [1] ALMEIDA PAGGI,T. **Decomposição de sinais eletromiográficos de superfície misturados linearmente utilizando análise de componentes independentes**. 2012. 175f. Dissertação(Mestrado em Engenharia Elétrica) - Faculdade de Engenharia Elétrica e de Computação, UNICAMP, Campinas, 2012.
- [2] TYGEL FREIHOF,A. **Métodos de fatoração de matrizes não-negativas para separação de sinais musicais**. 2009. 122f. Dissertação(Mestrado em Engenharia Elétrica) - Instituto Alberto Luiz Coimbra de Pós-Graduação e Pesquisa de Engenharia , UFRJ, Rio de Janeiro, 2009.
- [3] CHAME MAGRANI,I. **Métodos para separação de vozes a partir de misturas pré-gravadas**. 2016. 161f. Projeto de graduação(Graduação em Engenharia Eletrônica e de Computação) - Curso de Engenharia Eletrônica e de Computação da Escola Politécnica, UFRJ, Rio de Janeiro, 2016.
- [4] Laporte Menezes Victorio,L. **Algoritmos de separação cega de sinais de áudio no domínio da frequência em ambientes reverberantes: Estudo e comparações**. 2010. 143f. Dissertação(Mestrado em Engenharia Elétrica) - Instituto Alberto Luiz Coimbra de Pós-Graduação e Pesquisa de Engenharia , UFRJ, Rio de Janeiro, 2010.
- [5] OLIVEIRA RODRIGUES,B;QUEIROZ APARECIDO,M;FILHO VIEIRA,J. **Blind source separation by multiresolution analysis using AMUSE algorithm**. Multi-Science Journal ,40-45,2015.
- [6] SANTOS BORBA,M;MAGALHÃES,F;FERREIRA,F;PEIXOTO MYRIAM,Z. **Análise da fatoração de matrizes não-negativas para a separação de fontes acústicas via distância euclidiana quadrática e divergência de Kullback-Leibler**, In: Congresso de Engenharia de Áudio, 13, 2015, São Paulo(SP).
- [7] LIMA, Elon L. **Álgebra Linear**. Rio de Janeiro: IMPA , 2014.
- [8] KAY, Steven M. **Intuitive Probability and Random Process Using MATLAB**. New York: Springer,2006.
- [9] ALBUQUERQUE, Paulo J. **Probabilidades,Variáveis Aleatórias e Processos Estocásticos**. Rio de Janeiro: PUC-Rio,2008.